

Homework 4

Design Solution for data pipeline

Summary

Для задачі збору, OCR-обробки, анотації та аналізу direct marketing materials оптимальним є storage-centric pipeline: великі файли зберігаються в object storage, Airflow передає між задачами тільки URI/metadata, OCR і metadata extraction виконуються окремими сервісами, а результати потрапляють у metadata DB, annotation tool і analytics layer. Такий підхід відповідає патерну ETL with Explicit External Storage, де кожен етап пише результат у durable storage, що полегшує retry, debug, backfill і аудит.

Серед аналогів можна виділити дві групи: ad libraries на кшталт Meta Ad Library / Google Ads Transparency Center та creative analytics платформи на кшталт VidMob / CreativeX. Цінність створює не просто архів зображень і OCR-текстів, а нормалізована модель ознак креативу: бренд, індустрія, регіон, СТА, промо, візуальний стиль, дисконт, юридична інформація, мова, маркетинговий канал.

1. Analyze functional and non-functional requirements

Проект передбачає побудову data pipeline для збору, обробки, OCR-розпізнавання, анотації та подальшого аналізу матеріалів прямого маркетингу з різних регіонів країни. До таких матеріалів належать флаери, листівки, плакати, купони, фото зовнішньої реклами, PDF-буклети, POS-матеріали, скриншоти SMS, email або месенджер-розсилок. Основна бізнес-мета системи полягає не просто в накопиченні зображень або OCR-текстів, а у створенні структурованого сховища ознак креативів: бренд, індустрія, регіон, дата, тип пропозиції, СТА, мова, формат, знижка, візуальний стиль і потенційна цільова аудиторія.

Для оцінки масштабу приймається, що система оброблятиме близько 50 тис. маркетингових матеріалів на місяць, що приблизно відповідає 100 тис. сторінок або зображень для OCR. Очікуваний обсяг сирих даних становить 300–500 GB на місяць. Якщо зберігати 90 днів активної історії, то hot storage становитиме приблизно 1.2 TB raw data, а разом із preview, OCR JSON та іншими похідними артефактами — близько 1.5 TB активного object storage. Середня кількість користувачів системи — приблизно 10 анотаторів, а близько 5% сторінок потребуватимуть ручної валідації чи семантичної розмітки. Цільова затримка від завантаження до можливості пошуку має становити 15–30 хвилин для штатного навантаження.

Функціонально система має підтримувати багатоканальний режим завантаження: web або mobile upload, email inbox, SFTP/API від партнерів, а також ручний bulk upload. Після надходження матеріалу pipeline повинен виконати перевірку формату, розміру, пошкодження файлу, наявності базових метаданих і дублювання. Для дедуплікації доцільно використовувати hash-значення для виявлення майже однакових зображень. Далі виконується preprocessing: розділення PDF на сторінки, нормалізація зображень, rotation, crop, de-skew, стиснення та генерація thumbnail. Після цього OCR витягує текст і layout, а metadata extraction service перетворює OCR-вихід і контекст файлу на канонічні поля: регіон, місто, бренд, індустрія, ціна, знижка, промо, тип креативу, мова та джерело. Окремо потрібна human-in-the-loop annotation platform, де анотатори перевіряють і уточнюють semantic labels, creative type, message type, offer type, emotional tone та visual style.


Нефункціонально система має витримувати середнє навантаження близько 5 тис. сторінок на день і пікове навантаження до 20 тис. сторінок на день. Важливою вимогою є надійність: якщо один етап падає, система не повинна повторно виконувати всі попередні кроки. Тому архітектура має бути storage-centric: кожен етап зберігає результат у durable storage, а наступний етап читає його звідти. Це відповідає лекційному патерну **ETL with Explicit External Storage**, де проміжні результати зберігаються в S3/GCS/HDFS, що спрощує retry, debug, rerun, backfill і observability. Airflow у такій архітектурі не переносить великі файли між задачами; він передає тільки URI,

material_id, manifests і невеликі control records. Це знижує ризик перевантаження metadata plane і робить pipeline придатним до масштабування.

З погляду security і compliance, система має передбачати IAM/RBAC, encryption, audit logs, розділення доступів між ingestion, annotation і analytics, а також політику маскування потенційних персональних даних перед ручною анотацією. У матеріалах можуть траплятися телефони, адреси, імена або інші чутливі дані, тому raw materials і annotated datasets мають мати різні політики доступу. З погляду контролю витрат, створення MVP не повинно починатися з дорогого кластеру, ручного OCR або власної annotation системи. Доцільніше використати вже готовий OCR, object storage, Airflow, Cloud SQL PostgreSQL і Label Studio, а окремий search додати пізніше, коли стане зрозуміло, які саме пошукові патерни потрібні замовникам.

2. Create raw solution diagram

Airflow не переносить файли або DataFrames між тасками. Він оркеструє етапи й передає тільки material_id, URI, статуси та small metadata records. Це відповідає лекційному принципу, що persistent external storage робить pipeline більш модульним, debug-friendly і придатним до rerun/backfill.



3. Analyze solution for each service

Для реалізації обирається **GCP**, оскільки проведення дослідження показує, що GCP має найзбалансованіший профіль для стартового рішення: зрозумілий managed Airflow, serverless compute через Cloud Run, прозоре logging/monitoring і можливість почати без окремого дорогого search cluster.

Перший ключовий сервіс — orchestration. Для нього можна розглядати три підходи: self-hosted Apache Airflow, managed Airflow у GCP або розроблення власного workflow engine. Self-hosted Airflow дає DAG orchestration, retries, scheduling, UI і велику екосистему операторів, але потребує самостійного управління scheduler, workers, metastore, secrets, upgrades, logs, autoscaling і backup. Managed Airflow, тобто Cloud Composer / Managed Service for Apache Airflow, дає готовий control plane, web UI, інтеграцію з GCP IAM і зменшує операційне навантаження. Натомість зберігається помірний cloud lock-in і певний always-on baseline cost. Build from scratch у цьому випадку недоцільний: довелося б створювати scheduler, dependency engine, retry logic, backfill, UI,

RBAC, audit і monitoring, що означає дуже високий технічний борг. Тому для MVP рекомендовано managed Airflow, оскільки задача є типовою batch/document-processing pipeline з чіткими залежностями, retry та data quality checks.

Другий сервіс — storage. Тут головним архітектурним рішенням є використання object storage як центрального сховища сирих і проміжних артефактів. Open-source альтернатива — MinIO або Ceph — дає S3-like API, versioning і bucket policies, але потребує самостійної підтримки replication, backup, lifecycle management, monitoring і disaster recovery. Managed object storage у GCP, тобто Google Cloud Storage, одразу надає durable storage, IAM, lifecycle policies, encryption і масштабування. Build from scratch для object storage не має сенсу. Для цього проєкту GCS має бути source of truth для raw files, processed files, OCR JSON, annotation exports і model-ready datasets. Це також підтримує vendor-neutral migration, оскільки binary artifacts зберігаються окремо від orchestration і search layers. Object storage визначено як незмінний центр архітектури незалежно від провайдера.

Третій сервіс — OCR. Open-source варіантами є Tesseract, PaddleOCR, OpenCV-based preprocessing і власні layout models. Вони знижують витрати і дають контроль над даними, але потребують CPU/GPU scaling, evaluation harness, model tuning, quality monitoring і складної підтримки нестандартних layouts. Managed OCR/API у GCP — Cloud Vision Document Text Detection або Document AI — дає OCR, масштабування, SLA і швидкий time-to-value. Проте потрібно задати normalization layer, quality checks, confidence thresholds і fallback path. Build from scratch для OCR недоцільний на MVP, бо потребує dataset collection, labeling, training, serving, evaluation і MLOps. Для direct marketing materials важливо розпізнавати не лише символи, а й headings, coupon text, CTA, дрібний legal copy, layout і visual emphasis. Тому managed OCR/document understanding майже завжди дає кращий time-to-value, ніж pure open-source OCR, а власний OCR має сенс лише у privacy-sensitive або high-volume production сценарії.

Четвертий сервіс — annotation. Найкращим open-source вибором є Label Studio. Він дає проєкти, task queues, review flows, export у JSON, integration з cloud storage і можливість ML-assisted labeling. Але його потрібно розгорнути, підключити до PostgreSQL, налаштувати SSO/RBAC, backup і експорт schema. Managed labeling SaaS зменшує витрати, але підвищує lock-in і ризик передачі даних third-party vendor. Build from scratch annotation UI не виправданий: потрібно створювати user management, labeling interface, review workflow, comments, QA, export і audit trail. Для цієї задачі Label Studio на Cloud Run із Cloud SQL PostgreSQL є найкращим компромісом: він не змушує будувати annotation system з нуля, але залишає контроль над даними й annotation schema. Label Studio добре відповідає такому use case, бо працює з external storage і зберігає annotation state окремо від binary storage.

П'ятий блок — metadata database and search. Для MVP доцільно використати Cloud SQL PostgreSQL як канонічне сховище структурованих метаданих і state. PostgreSQL може зберігати material_id, URI, region, city, brand, industry, creative_type, OCR confidence, annotation status, processing status і JSONB-поля для гнучких ознак. На старті також можна використати PostgreSQL full-text search і pg_trgm для пошуку по OCR-тексту й атрибутах. Це дешевше й простіше, ніж одразу піднімати окремий search cluster. Managed search layer доцільно додавати пізніше, коли зросте обсяг індексу або з'являться складні вимоги. Build from scratch search engine не має сенсу, оскільки inverted index, ranking, analyzers і scaling є складними інженерними задачами. Отже, для MVP рекомендовано Cloud SQL PostgreSQL + FTS, а окремий OpenSearch/Vertex AI Search layer розглядати як production extension.


4. Pricing model and estimated monthly cost

100 000 OCR-сторінок на місяць, 1,5 ТБ активного об'єктного сховища, 30 користувачів, GCP us-central1, без урахування зарплат анотатора та ліцензій BI.

Component	Pricing model	monthly cost	Features	Advantages	Disadvantages
Managed Airflow / Cloud Composer	Environment/DCU/resource-based billing. Gen 2 Small fee shown as \$0.35/hour plus compute/storage components. (Google Cloud)	~\$300–340	DAGs, retries, UI, monitoring, scheduling.	Low Ops, course-aligned.	Always-on baseline.
Cloud Storage	GiB-hour storage + operation charges; Standard storage and Class A/B operations are listed separately. (Google Cloud)	~\$33–40	Raw/processed/OCR/annotation buckets.	Durable, cheap, scalable.	Lifecycle must be managed.
Cloud Vision OCR	Document Text Detection: first 1000 free, then \$1.50 / 1000 units. (Google Cloud)	~\$148.5	OCR text extraction.	Very low Ops; predictable unit cost.	Provider-specific output, so normalize JSON.
Cloud SQL PostgreSQL	vCPU + memory hourly; e.g., \$0.0413/vCPU-hour and \$0.007/GiB-hour in selected table. (Google Cloud)	~\$105–120	Metadata DB, annotation DB, FTS.	Managed backups/patching; one DB for MVP.	Search may need separation later.
Cloud Run services/jobs	CPU and memory per second; instance-based billing lists \$0.000018/vCPU-sec and \$0.000002/GiB-sec. (Google Cloud)	~\$80–120	Ingestion API, preprocessing jobs, metadata extractor, Label Studio hosting.	Serverless, scales with load.	containerization and IAM setup.
Monitoring/logging/misc	Logs/metrics/network/misc.	~\$25–50	Alerts, logs, dashboards.	Observability.	Can grow if logs are kept too long.

Орієнтовна щомісячна вартість GCP MVP: ~\$700–850/місяць, без урахування ЗП для анотацій людям.

5. Create final diagram with specific services



- Джерела даних** — цей блок покриває функціональну вимогу багатоканального збору direct marketing materials із фото, сканів, PDF, email/месенджерів і партнерських каналів.
- Cloud Run Ingestion API** — приймає вхідні матеріали, створює первинний `material_id` і запускає подальшу обробку без необхідності постійно підтримувати власний сервер.
- Validation + Dedup** — перевіряє формат, розмір, цілісність і дублікати файлів, щоб не витрачати OCR/annotation ресурси на невалідні або повторні матеріали.
- Google Cloud Storage RAW** — зберігає сирі файли як незмінне джерело правди
- Cloud Composer / Airflow** — оркеструє DAG, залежності між задачами.
- Cloud Run Pre-processing Jobs** — виконує domain-specific підготовку файлів: split PDF, resize, de-skew, rotation, crop і генерацію проміжних артефактів.
- Google Cloud Storage Processed** — зберігає оброблені версії матеріалів, щоб OCR, metadata extraction і annotation могли працювати з однаковими підготовленими файлами.
- Cloud Vision OCR** — забезпечує managed OCR для витягування тексту з флаєрів, сканів, фото, PDF і скриншотів без розгортання власної OCR-інфраструктури.
- GCS OCR JSON** — зберігає результат OCR у структурованому JSON-форматі, щоб його можна було повторно використовувати для metadata extraction, search і annotation.
- Metadata Extraction Service** — перетворює OCR-текст і контекст файлу на бізнес-ознаки креативу: бренд, індустрію, регіон, СТА, знижку, мову, тип пропозиції та creative type.
- Cloud SQL PostgreSQL** — зберігає канонічні метадані, статуси обробки, annotation state і зв'язки між raw files, OCR output та фінальними labels.
- PostgreSQL FTS / pg_trgm** — забезпечує MVP-рівень пошуку по OCR-тексту, брендах, регіонах та індустріях без запуску окремого дорогого search cluster.
- Label Studio on Cloud Run** — дає human-in-the-loop annotation interface для ручної валідації індустрій, СТА, message type, visual style, tone і target audience.
- GCS Annotated Dataset** — зберігає фінальні labels та exports у переносимих форматах для подальшої аналітики, навчання моделей і повторного використання.
- BigQuery** — агрегує очищені metadata, OCR-результати та annotation outputs у аналітичні таблиці для дослідження трендів креативів.
- Looker Studio** — надає dashboards для аналізу маркетингових матеріалів за регіонами, індустріями, брендами, СТА, типами промо та форматами креативів.
- Cloud Monitoring + Alerts** — забезпечує observability для pipeline: помилки DAG, затримки, failed tasks, проблеми ingestion, OCR failures і порушення SLA.